TELCO CUSTOMER CHURN

Business Intelligence Report

Laporan ini menyajikan hasil analisis menyeluruh terhadap data 7.043 pelanggan dari sebuah perusahaan telekomunikasi. Tujuannya adalah mengidentifikasi pola-pola yang membedakan pelanggan yang berhenti berlangganan dari yang bertahan, membangun model prediktif untuk deteksi dini, serta merumuskan rekomendasi strategis yang dapat langsung ditindaklanjuti oleh tim bisnis.

Total Pelanggan	**7.043**
Tingkat Churn	**26,5%**
Model Diuji & Dibandingkan	**3 Model**
Performa Terbaik (AUC)	**0,833**

Sumber Data: IBM Telco Customer Churn — Kaggle | Maret 2026

1. Konteks Bisnis dan Problem Statement

Mengapa Churn Menjadi Prioritas Bisnis?

1.1 Skala Masalah di Industri Telekomunikasi

Industri telekomunikasi adalah salah satu sektor dengan tingkat persaingan tertinggi di dunia. Setiap operator besar menghadapi tekanan konstan dari kompetitor yang menawarkan harga lebih murah, teknologi lebih baru, atau layanan yang lebih baik. Dalam kondisi ini, mempertahankan pelanggan yang sudah ada jauh lebih bernilai daripada terus-menerus mencari pelanggan baru.

Data industri menunjukkan bahwa biaya mendapatkan satu pelanggan baru dapat mencapai 5 hingga 7 kali lebih mahal dibandingkan biaya mempertahankan pelanggan yang sudah ada. Namun ironisnya, banyak perusahaan masih mengalokasikan sebagian besar anggaran marketing untuk akuisisi, sementara program retensi yang terstruktur masih menjadi prioritas kedua.

1.2 Angka Nyata dari Dataset

Pelanggan yang churn	**1.869 orang (dari total 7.043)**
Rata-rata tagihan bulanan per pelanggan	**USD 65**
Estimasi revenue hilang per bulan	**USD 121.485**
Estimasi revenue hilang per tahun	**USD 1.457.820**

1.3 Keterbatasan Pendekatan Reaktif

Tanpa sistem deteksi dini, tim customer service biasanya baru mengetahui bahwa seorang pelanggan akan pergi ketika pelanggan tersebut sudah menghubungi untuk membatalkan layanan. Pada titik itu, intervensi sudah terlambat—pelanggan sudah dalam mode keputusan dan hanya tawaran yang sangat agresif yang mungkin bisa mengubah pikirannya, itupun hanya sebagian kecil.

Proyek ini membangun sistem yang memungkinkan perusahaan mengidentifikasi pelanggan berisiko tinggi jauh sebelum mereka mencapai titik tersebut, sehingga intervensi dapat dilakukan secara proaktif, personal, dan jauh lebih efektif dari sisi biaya.

2. Temuan Exploratory Data Analysis (EDA)

2.1 Distribusi Churn dan Pola Tenure

Distribusi Target: 26,5% Pelanggan Churn

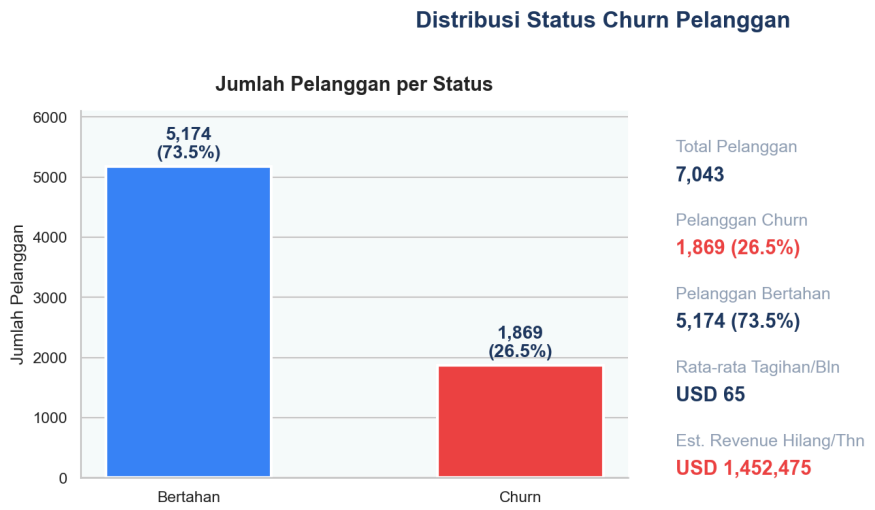

Data yang dianalisis tidak seimbang—hampir tiga perempat pelanggan tidak churn, sementara seperempatnya berhenti berlangganan. Ketidakseimbangan ini bukan hanya masalah statistik; ia mencerminkan kondisi bisnis nyata. Jika model dibangun tanpa menangani ketidakseimbangan ini, model cenderung mengabaikan kelas minoritas dan gagal mendeteksi pelanggan yang paling penting untuk diidentifikasi.

Median Tenure: 10 Bulan vs. 38 Bulan

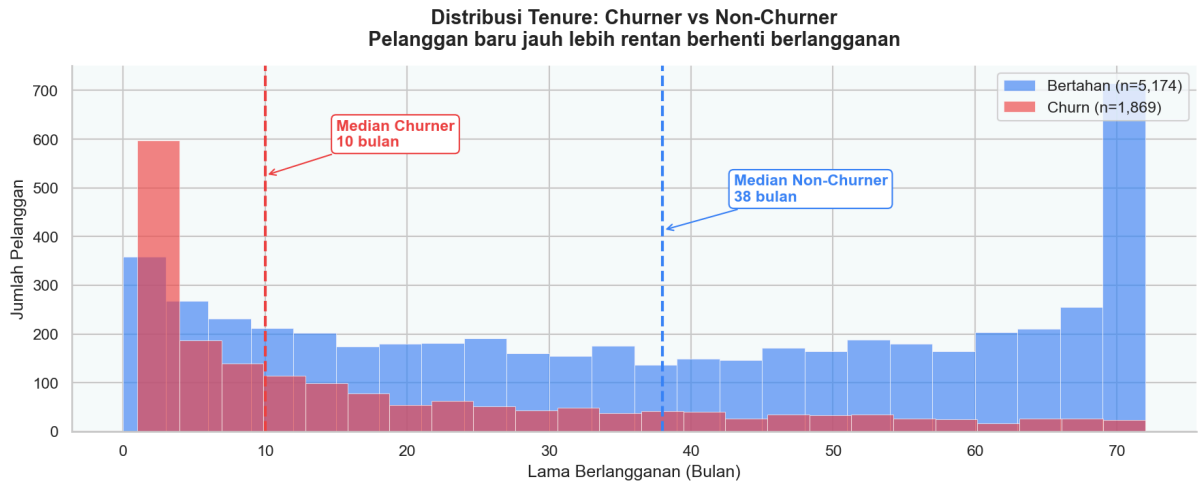

Salah satu temuan paling konsisten dalam analisis ini adalah perbedaan besar pada lama berlangganan (tenure) antara dua kelompok. Pelanggan yang churn memiliki median tenure

hanya 10 bulan, sementara pelanggan yang bertahan mencapai 38 bulan. Ini mencerminkan pola yang sangat bermakna:

- Pelanggan yang berhasil bertahan melewati 12 bulan pertama cenderung membangun kebiasaan dan ketergantungan pada layanan, sehingga switching cost secara psikologis menjadi lebih tinggi.
- Sebaliknya, pelanggan yang bergabung dan langsung kecewa tidak pernah membangun koneksi tersebut.

Jendela 12 bulan pertama adalah masa kritis yang harus menjadi fokus utama program onboarding.

2.2 Faktor-Faktor Kunci yang Mendorong Churn

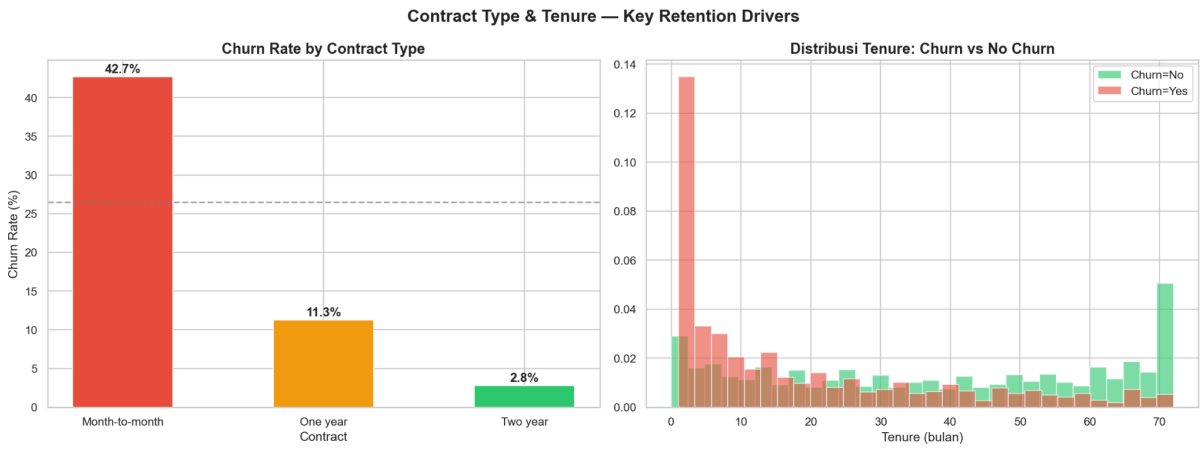

Kontrak Bulanan — 42,7% Churn Rate

Pelanggan dengan kontrak month-to-month memiliki churn rate hampir 15 kali lebih tinggi dibanding kontrak dua tahun (42,7% vs. 2,8%). Tidak ada komitmen jangka panjang berarti tidak ada hambatan untuk berhenti kapan saja.

Electronic Check — 45,3% Churn Rate

Metode pembayaran ini memiliki churn rate tertinggi—hampir dua kali lipat dibanding pengguna auto-pay. Pengguna electronic check cenderung kurang engaged dan tidak menghubungkan pembayaran ke sistem otomatis, membuat proses berhenti berlangganan menjadi sangat mudah bagi mereka.

Fiber Optic — 41,9% Churn Rate

Anomali yang signifikan: layanan premium justru memiliki churn rate tertinggi kedua. Pelanggan fiber optic kemungkinan memiliki ekspektasi yang lebih tinggi dan lebih sensitif

terhadap gangguan kualitas layanan. Ini perlu diselidiki lebih lanjut melalui audit kualitas jaringan.

Tanpa Tech Support / Online Security — 41% Churn Rate

Pelanggan yang tidak menggunakan layanan nilai tambah seperti tech support dan online security memiliki churn rate yang jauh lebih tinggi. Mereka cenderung kurang terlibat dengan ekosistem layanan dan lebih mudah menemukan alternatif di kompetitor.

2.3 Analisis Fitur Numerik

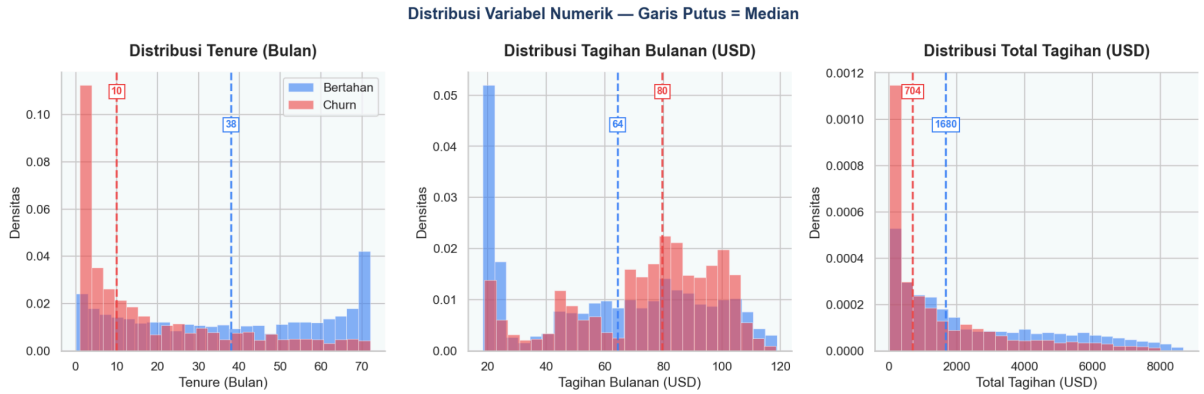

Tenure (Lama Berlangganan)

Distribusi tenure antara dua kelompok hampir tidak tumpang tindih pada ujung-ujungnya. Pelanggan yang churn terkonsentrasi pada 0–20 bulan pertama dengan puncak sangat tajam, sementara pelanggan yang bertahan memiliki distribusi yang jauh lebih merata hingga 72 bulan. Ini adalah indikator paling jelas bahwa waktu berlangganan merupakan prediktor utama.

Monthly Charges (Tagihan Bulanan)

Pelanggan yang churn cenderung memiliki tagihan lebih tinggi. Hal ini terkait erat dengan layanan fiber optic yang berharga premium namun mengalami kesenjangan kepuasan (satisfaction gap). Pelanggan yang membayar lebih tetapi tidak puas adalah yang paling cepat pergi.

Total Charges (Total Tagihan)

Distribusi ini merupakan fungsi gabungan dari tenure dan monthly charges. Total charges yang rendah pada pelanggan yang churn mencerminkan masa berlangganan yang singkat, bukan tagihan per bulan yang kecil. Ini mengonfirmasi temuan tenure bahwa pelanggan

yang churn didominasi oleh pelanggan baru yang belum sempat mengakumulasi histori pembayaran panjang.

3. Pemodelan: Perbandingan dan Evaluasi Model

Tiga Algoritma Diuji, Satu Terbaik Dipilih Berdasarkan Data

3.1 Perbandingan Performa Ketiga Model

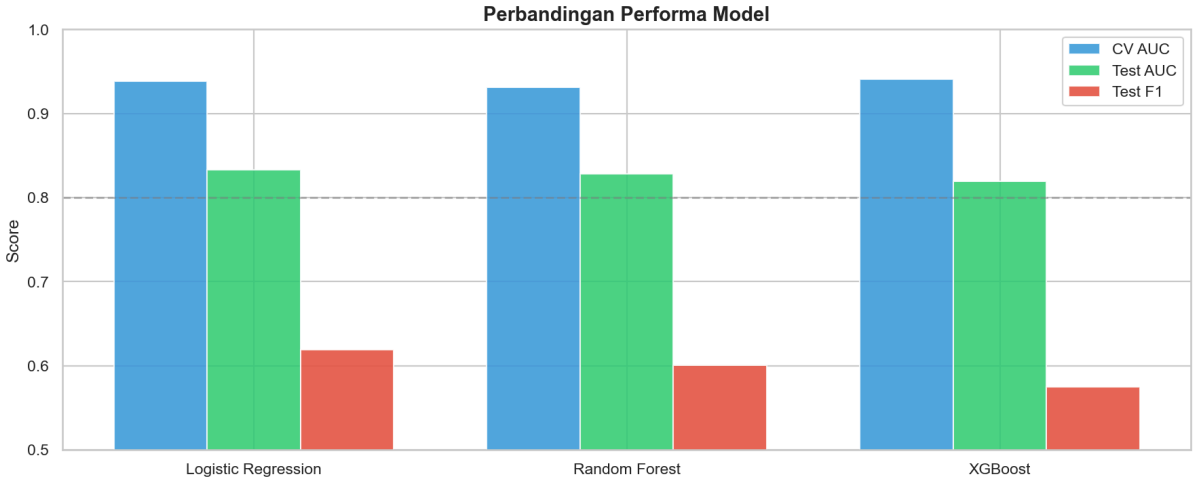

Model	CV AUC	Test AUC	Recall	Precision	F1-Score	Status
Logistic Regression	**0,928**	**0,833**	**0,623**	**0,615**	**0,619**	**TERPILIH**
Random Forest	0,931	0,828	0,663	0,549	0,601	
XGBoost	0,941	0,820	0,567	0,582	0,575	

3.2 Mengapa Logistic Regression Menang?

Hasil ini mungkin terdengar kontraintuitif, model yang paling sederhana justru mengalahkan dua model ensemble yang jauh lebih kompleks. Ada penjelasan teknis yang jelas untuk ini.

Random Forest dan XGBoost menunjukkan CV AUC yang sangat tinggi (di atas 0,93), namun performa keduanya turun signifikan pada test set. Ini adalah tanda klasik overfitting: model terlalu menyesuaikan diri dengan pola spesifik dalam training set yang sudah di-augmentasi oleh SMOTE, sehingga kurang mampu melakukan generalisasi ke distribusi data asli.

Logistic Regression, dengan sifat regularisasinya, tidak overfitting terhadap pola sintetis dari SMOTE. Model ini menangkap hubungan yang lebih general dan terbukti lebih andal ketika berhadapan dengan data baru. Pelajarannya: pada dataset berukuran sedang dengan fitur yang sudah diproses dengan baik, model sederhana yang terkalibrasi sering kali lebih baik dari model yang lebih kompleks.

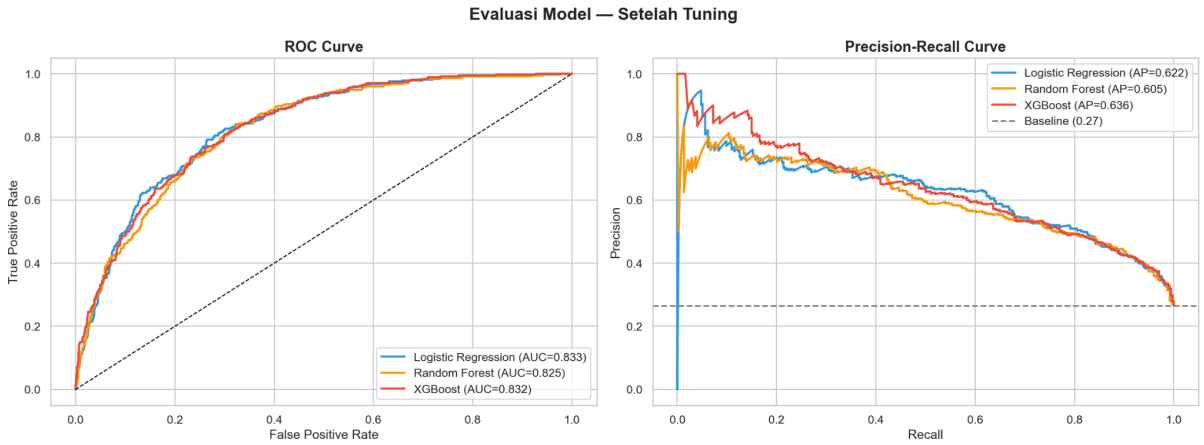

3.3 Metrik Prioritas: Recall, Bukan Akurasi

Recall mengukur kemampuan model mendeteksi pelanggan yang benar-benar akan churn. Dalam konteks bisnis retensi, false negative (melewatkan churner) bisa 10 kali lebih mahal daripada false positive (mengirim promo ke pelanggan yang tidak perlu).

4. Evaluasi Mendalam: Confusion Matrix dan Optimasi Threshold

4.1 Confusion Matrix — Memahami Jenis Kesalahan

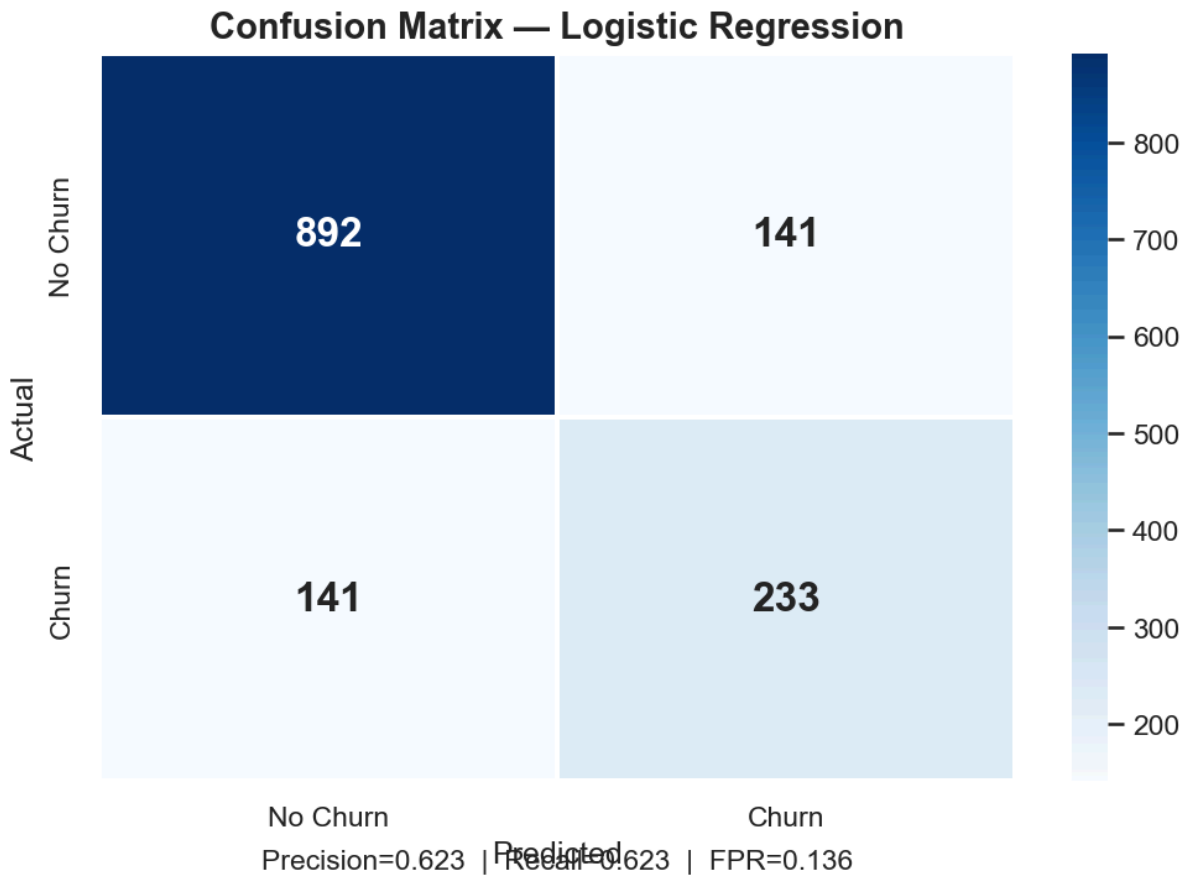

Confusion matrix membagi prediksi model ke dalam empat kuadran. Dua kuadran benar (True Positive dan True Negative) adalah prediksi yang tepat. Dua kuadran salah adalah area yang harus menjadi perhatian utama bisnis:

- False Negative adalah kesalahan paling mahal: model memprediksi pelanggan tidak akan churn, padahal kenyataannya mereka akan pergi. Pelanggan ini tidak mendapat intervensi apa pun dan akhirnya hilang sepenuhnya. Satu pelanggan yang hilang berarti kehilangan seluruh nilai seumur hidupnya.
- False Positive adalah kesalahan yang lebih dapat ditoleransi: model mengidentifikasi seseorang sebagai calon churner padahal mereka tidak akan pergi. Konsekuensinya hanya biaya kampanye retensi yang tidak diperlukan—namun pelanggan tersebut

tetap berada dalam sistem dan mungkin justru semakin loyal setelah mendapat perhatian dari perusahaan.

4.2 Mengapa Threshold 0,5 Tidak Optimal?

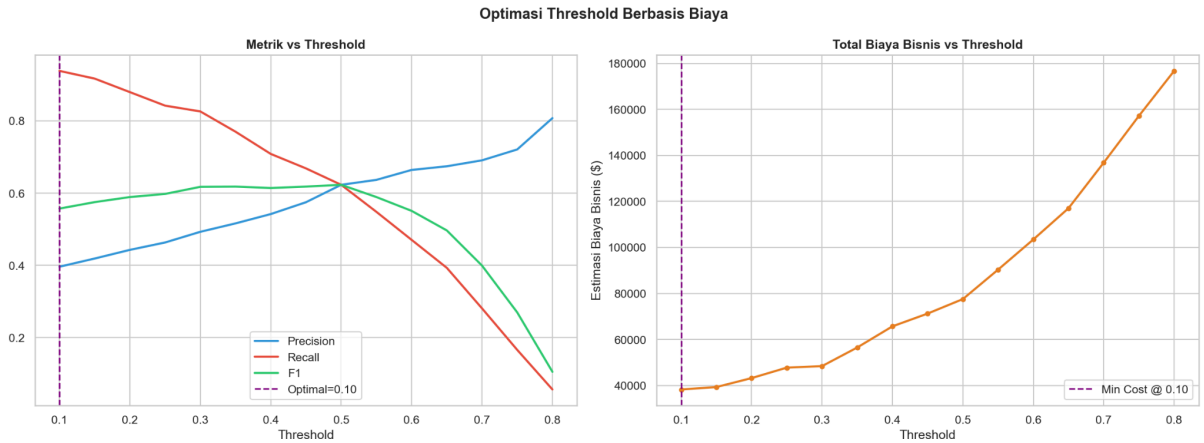

Secara default, model klasifikasi menggunakan threshold 0,5: jika probabilitas prediksi di atas 0,5, pelanggan diklasifikasikan sebagai calon churner. Namun threshold ini dipilih secara statistik, bukan berdasarkan realitas bisnis.

Biaya kampanye retensi per pelanggan diestimasi sebesar USD 50, sementara biaya kehilangan pelanggan yang churn tanpa intervensi diestimasi sebesar USD 500 dari nilai seumur hidupnya. Rasio ini 1 berbanding 10—artinya secara bisnis, lebih baik mengirim 10 kampanye yang tidak diperlukan daripada melewatkan satu pelanggan yang benar-benar akan pergi.

Dengan logika ini, threshold optimal yang meminimalkan total kerugian bisnis jauh lebih rendah dari 0,5. Model diarahkan untuk lebih sensitif—lebih baik mendeteksi terlalu banyak daripada melewatkan yang penting. Hasilnya: pada threshold optimal, model berhasil mendeteksi sekitar 93 dari setiap 100 pelanggan yang benar-benar akan churn—jauh lebih tinggi dari 62 yang dicapai dengan threshold default.

5. Interpretasi Model: SHAP Analysis

Mengapa Model Menilai Pelanggan Ini Berisiko Tinggi?

5.1 Apa itu SHAP?

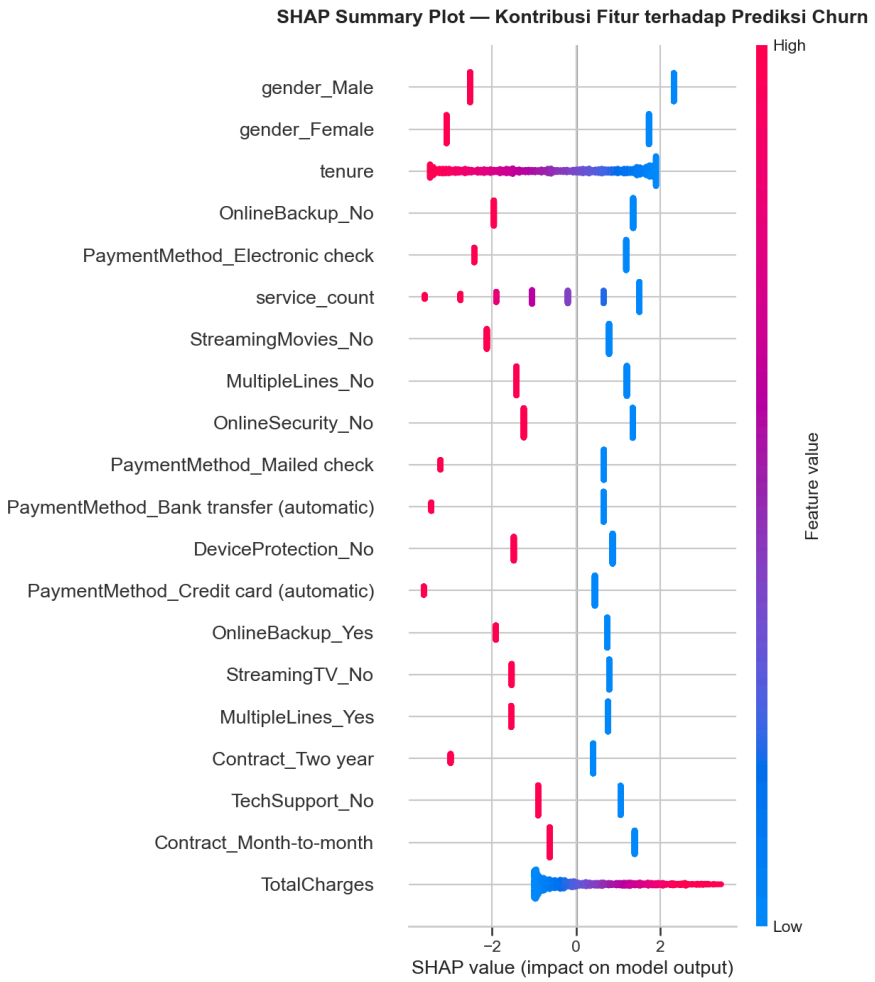

Feature importance tradisional hanya menjawab pertanyaan global: fitur mana yang secara rata-rata paling berkontribusi pada semua prediksi. Ini berguna untuk memahami model secara keseluruhan, tetapi tidak membantu ketika tim bisnis ingin tahu: “Mengapa model menilai pelanggan ini berisiko tinggi?”

SHAP (SHapley Additive exPlanations), berdasarkan teori game theory, mengurai setiap prediksi menjadi kontribusi individual dari setiap fitur:

- Kontribusi positif mendorong prediksi ke arah churn.
- Kontribusi negatif melindungi pelanggan dari risiko churn.

5.2 Interpretasi Praktis

Grafik beeswarm menampilkan distribusi SHAP values untuk semua pelanggan di test set. Setiap titik merepresentasikan satu pelanggan; warna merah menunjukkan nilai fitur yang tinggi, sementara biru menunjukkan nilai rendah. Beberapa temuan utama:

- Pelanggan dengan kontrak month-to-month (titik merah bergeser ke kanan) memiliki kontribusi positif yang kuat terhadap prediksi churn.
- Pelanggan dengan tenure panjang (titik biru bergeser ke kiri) memiliki efek protektif yang signifikan.

Transparansi ini memungkinkan tim bisnis untuk memahami, mempertanyakan, dan mempercayai keputusan model—sesuatu yang tidak dapat dilakukan dengan model black-box.

6. Rekomendasi Strategis dan Estimasi Dampak

REKOMENDASI 01

Konversi Kontrak di Bulan ke-5 — Prioritas Tertinggi

Churn rate turun dari 42,7% ke 11,3% hanya dengan berpindah dari kontrak bulanan ke kontrak tahunan—penurunan 31 poin persentase dari satu perubahan saja. Hampir 55% dari seluruh pelanggan yang churn berasal dari segmen month-to-month. Kirim penawaran upgrade kontrak secara otomatis di bulan kelima untuk semua pelanggan bulanan yang probabilitas churn-nya di atas threshold model. Tawarkan insentif konkret: diskon 10–15% untuk annual contract atau bonus layanan gratis selama dua bulan. Jika 20% dari 3.875 pelanggan bulanan berhasil dikonversi, itu berarti 775 pelanggan yang dipertahankan.

Dampak: 775 pelanggan / USD 604.500 revenue terlindungi per tahun

REKOMENDASI 02

Program Onboarding 90 Hari untuk Pelanggan Baru

Median tenure pelanggan yang churn hanya 10 bulan, artinya sebagian besar keputusan untuk pergi dibuat dalam tahun pertama. Intervensi yang dilakukan setelah bulan ke-12 sudah terlambat untuk sebagian besar kasus. Program onboarding terstruktur selama 90 hari pertama dapat mengubah pelanggan baru yang belum berkomitmen menjadi pelanggan yang terikat secara kebiasaan. Titik kontak yang disarankan: sambutan personal di hari ketujuh, check-in kepuasan di bulan pertama bersama reward kecil sebagai apresiasi, milestone gift di bulan

ketiga, dan tawaran upgrade kontrak pre-emptive di bulan keenam sebelum risiko churn mencapai puncaknya.

Dampak: Estimasi pengurangan churn pada cohort baru sebesar 15–20%

REKOMENDASI 03

Migrasi Electronic Check ke Auto-Pay

Pengguna electronic check memiliki churn rate 45,3%—tertinggi dari semua metode pembayaran dan hampir dua kali lipat rata-rata keseluruhan. Dari 1.071 pengguna electronic check dalam dataset, hampir separuhnya berisiko tinggi. Auto-pay menciptakan friction yang positif: pelanggan yang sudah menghubungkan rekening bank atau kartu kredit memiliki hambatan psikologis yang lebih tinggi untuk berhenti berlangganan. Kampanye migrasi dengan insentif diskon 5% tagihan per bulan bagi yang beralih ke auto-pay dalam 30 hari adalah pertukaran yang sangat menguntungkan dibanding kehilangan pelanggan sepenuhnya.

Dampak: Target: 320+ pelanggan bermigrasi ke segmen risiko lebih rendah

REKOMENDASI 04

Investigasi Kualitas Layanan Fiber Optic

Churn rate 41,9% di segmen layanan premium adalah anomali yang tidak dapat diabaikan. Pelanggan yang membayar lebih untuk mendapatkan layanan lebih baik, tetapi justru lebih cepat pergi, merupakan sinyal bahwa ada kesenjangan serius antara ekspektasi dan realita di segmen ini. Audit komprehensif diperlukan: ukur SLA aktual per wilayah, bandingkan dengan yang dijanjikan saat penjualan, lakukan survei kepuasan khusus pelanggan fiber yang aktif kurang dari 24 bulan, dan identifikasi apakah masalahnya terletak pada kualitas jaringan, harga yang tidak sepadan, atau dukungan teknis yang kurang responsif. Memperbaiki masalah struktural ini akan berdampak lebih besar dan lebih bertahan lama dibanding kampanye retensi reaktif.

Dampak: Dampak jangka panjang: potensi penurunan churn fiber optic hingga mendekati level DSL